

Diseño y Desarrollo de Plataforma de Apreciación Artística para Personas con Discapacidad Visual

**Memoria de Titulación
para optar al título de Ingeniero Civil Telemático**

22-06-2026

Alexey Nikolay Mitjaew Hupat

Contents



1	Introducción	5
1.a	Contexto y Problema	6
1.b	Oportunidad Tecnológica	7
1.c	Solución Propuesta	8
1.d	Objetivos	9
2	Marco Teórico	10
2.a	Modelos de Lenguaje Multimodales	11
2.b	Modelos Generativos de Audio y TTS	12
2.c	Estándares de Accesibilidad	13
3	Estado del Arte	14
3.a	Accesibilidad Cultural Tradicional	15
3.b	Comparación de Alternativas	16
3.c	Modelos Multimodales Evaluados	18
3.d	Modelos de Audio y Voz Evaluados	19
4	Desarrollo de la Plataforma	21
4.a	Requisitos Funcionales	22

Contents (ii)



4.b	Requisitos No Funcionales	23
4.c	Arquitectura General	24
4.d	Módulos del Sistema	26
4.e	Catálogo y Modelo de Datos	27
4.f	Módulos de Generación	28
4.g	Sonidos Ambientales: Heurística	31
4.h	Prompt para Extracción Semántica	32
4.i	Frontend	33
4.j	Limitaciones	34
5	Resultados	35
5.a	API Gateway	36
5.b	Frontend	37
5.c	Caso de Estudio: “El Aquelarre” (Goya)	39
5.d	Resultados: Audio Descriptivo	40
5.e	Resultados: Narraciones de Contexto	41
5.f	Resultados: Sonidos Ambientales y TTS	42

Contents (iii)



6	Conclusión	43
6.a	Síntesis de Resultados	44
6.b	Trabajo Futuro y Potencial	45
7	Preguntas	46

1 Introducción



- El acceso equitativo al arte es un componente esencial del desarrollo cultural y social.
- Las personas con discapacidad visual enfrentan barreras significativas para disfrutar obras visuales en condiciones comparables al resto del público.
- Las soluciones de accesibilidad convencionales (texto alternativo, audioguías manuales, maquetas táctiles) no logran traducir la experiencia estética completa:
 - Composición, color, textura y simbolismo.



- La inteligencia artificial emerge como una oportunidad para reimaginar la transmisión de contenido artístico.
- Los modelos multimodales de lenguaje interpretan el contenido de una obra con profundidad semántica:
 - Identifican elementos, estilos, emociones y simbolismos.
- Los modelos generativos de audio transforman interpretaciones en experiencias sonoras inmersivas.
- Esta convergencia habilita una mediación artística automatizada y escalable.



Este proyecto desarrolla una alternativa de accesibilidad para consumo de contenido artístico orientado a personas con discapacidad visual.

Pipeline integrada de producción de piezas de audio:

- Modelos de lenguaje multimodales para interpretación de obras.
- Sistemas de síntesis de voz (TTS) para narración.
- Modelos generativos de audio para paisajes sonoros.
- Cliente web accesible conforme a estándares WCAG.

Objetivos



Objetivo General:

Mejorar la experiencia estética y promover la accesibilidad universal a las obras de arte para personas con discapacidad visual, mediante una plataforma que utiliza IA para transformar imágenes de obras en paisajes sonoros y descripciones auditivas significativas.

Objetivos Particulares:

1. Proveer un catálogo curado de obras de dominio público.
2. Generar audios descriptivos del contenido visual.
3. Crear narraciones con contexto histórico/biográfico.
4. Producir ambientes sonoros inmersivos.
5. Diseñar una interfaz centrada en accesibilidad.

Aportes principales: Objetivos 1 y 4. Contribuciones significativas en módulos 2 y 3.

2 Marco Teórico



- Sistemas de aprendizaje profundo que procesan, comprenden y generan texto en lenguaje natural.
- Extensión multimodal: integran contenido visual (imágenes) y auditivo.
- Capacidades clave para este proyecto:
 - Generar descripciones detalladas de escenas y composiciones artísticas.
 - Traducir elementos visuales en narrativas estructuradas.
 - Procesar entradas de voz en flujos conversacionales.



- **Generación de audio:** sistemas que crean sonidos y música a partir de prompts de texto.
 - Basados en arquitecturas de aprendizaje profundo (difusión, transformers).
 - Sintetizan desde sonidos ambientales hasta composiciones musicales.
- **Texto a Voz (TTS):** transforman texto escrito en habla sintética mediante NLP y síntesis de voz.

Estándares de Accesibilidad



- Marco normativo que guía el diseño de interfaces inclusivas.

WCAG (Pautas de Accesibilidad para el Contenido Web):

- Perceptibilidad, operabilidad, comprensibilidad y robustez.

Contexto chileno:

- Ley N.º 20.422: igualdad de oportunidades e inclusión social.
- Exigencias específicas para tecnologías asistivas.

Adopción en la plataforma:

- Compatibilidad con lectores de pantalla.
- Navegación por teclado.
- Descripciones alternativas y controles auditivos accesibles.

3 Estado del Arte



Prácticas museográficas convencionales:

- Audioguías, maquetas táctiles, textos en braille, recorridos guiados adaptados.
- Guías oficiales de accesibilidad para museos.

Programas institucionales:

- Experiencias multimediales MAC (Museo de Arte Contemporáneo, U. de Chile): audioguías, cápsulas subtituladas, lengua de señas.
- Museo Emilio Caraffa (Argentina): sala accesible con QR, audiodescripciones y paisajes sonoros.

Proyectos independientes:

- **Audioguiarte:** audioguías personalizadas y recorridos accesibles.
- **MiméticasLab:** recreación táctil de obras con impresión 3D.



Categoría	Ejemplos	Modalidades	Limitaciones
Accesibilidad museográfica	Audioguías, braille, signoguías	Audio, táctil, texto	Escalabilidad limitada, alta dependencia humana
Programas institucionales	MAC, Caraffa	Audio, video, señas	Alcance restringido a exposiciones específicas
Proyectos inclusivos	Audioguiarte, MiméticasLab	Audio narrativo, táctil	No universalizado ni automatizado
Investigación académica	MAIDR, arte a música	Texto, audio	Prototipos sin despliegue productivo
Plataformas digitales	Smartify, Google Arts & Culture	Imagen, texto, audio	Baja personalización en accesibilidad

Table 1: Estado del Arte en Accesibilidad Artística

Comparación de Alternativas (ii)



Brecha identificada

Las soluciones actuales requieren procesos manuales o semiautomáticos, sin coordinación eficiente entre modalidades. Esto limita la escalabilidad.



Criterios de selección: pesos abiertos, soporte multimodal nativo, inferencia cloud de bajo costo.

Llama V4 (Meta): código abierto. Arquitectura con fusión temprana multimodal:

- **Vision Encoder** (MetaCLIP) genera tokens visuales.
- **Early Fusion Layer** unifica tokens visuales y textuales antes del procesamiento profundo.
- Capas **Transformer** con **iRoPE** aplican atención cruzada bidireccional (texto ↔ imagen).
- Disponible vía proveedores cloud: Groq, Novita, TogetherAI.

GPT-4o (OpenAI): integración nativa texto-imagen-audio. Sin pesos liberados.

Gemini 1.5 (Google): procesamiento multimodal unificado. Sin pesos liberados.



Síntesis de voz (TTS):

- **Tacotron 2:** encoder-decoder con atención, genera espectrogramas mel autoregresivamente.
- **VITS:** síntesis end-to-end con flujos normalizadores y aprendizaje adversarial.
- **StyleTTS2:** modela variaciones de prosodia y timbre.
- **Kokoro-82M:** seleccionado. 82M parámetros, 3 voces en español, alta calidad. Soporte nativo para español. Basado en StyleTTS2.

Generación de audio ambiental:

- **AudioLDM:** seleccionado. Genera audio ambiental mediante difusión latente condicionada por descripciones textuales. Utiliza embeddings CLAP para mejorar la alineación semántica texto-sonido. Pesos abiertos y preentrenados disponibles.
- **I Hear Your True Colors:** VQVAE + transformers + CLIP. Sin pesos públicos.

Modelos de Audio y Voz Evaluados (ii)




Figure 1: Arquitectura de AudioLDM – Difusión Latente + CLAP

4 Desarrollo de la Plataforma

Requisitos Funcionales



- **Catálogo de obras:** construir, procesar y exponer un catálogo digital curado de obras de dominio público, con imágenes y metadatos.
- **Audio descriptivo:** generar descripciones textuales objetivas mediante modelos multimodales y convertirlas a audio con TTS.
- **Narración contextual:** extraer y sintetizar información histórica de fuentes autoritativas, producir narraciones auditivas.
- **Ambiente sonoro:** integrar modelos generativos de imagen a audio para producir paisajes sonoros.
- **Interfaz accesible:** cliente web conforme a WCAG, compatible con lectores de pantalla y navegación por teclado.

Requisitos No Funcionales



- **Accesibilidad:** interfaz intuitiva y compatible con herramientas asistivas.
- **Modularidad:** módulos de generación de contenido independientes y reemplazables.
- **Escalabilidad:** incorporar nuevas obras sin cambios estructurales.
- **Interoperabilidad:** servicios expuestos mediante API REST con endpoints documentados.



Modelo arquitectónico: cliente-servidor. Desacopla la interfaz de usuario del procesamiento computacionalmente intensivo.

API Gateway como componente central:

- Centraliza el acceso a funcionalidades heterogéneas bajo una interfaz uniforme.
- Aísla los servicios internos, permitiendo evolución independiente.
- Concentra tareas de alto costo computacional en entorno controlado.

Tecnología: Django + Django REST Framework.

- ORM, arquitectura MVT, ecosistema de paquetes.
- Autenticación, manejo de rutas y middleware integrados.

Arquitectura General (ii)




Figure 2: Arquitectura General del Sistema

Módulos del Sistema



La API Gateway orquesta 4 módulos funcionales:

1. **Catálogo:** gestiona los recursos del sistema y su persistencia.
2. **Generador de Audio Descriptivo:** transforma representaciones visuales en audios descriptivos. Utiliza Llama V4 para análisis de imágenes.
3. **Narrador de Contexto:** crea narraciones sobre el contexto histórico de cada obra a partir de fuentes autoritativas.
4. **Generador de Sonidos Ambientales:** sintetiza audio contextual con modelos autoalojados (AudioLDM) para representar las obras en formato interactivo.

Esta separación permite integrar servicios externos y soluciones autoalojadas en una arquitectura desacoplada y escalable.



Dataset: 30 obras artísticas de dominio público en formato JSON.

autor	título	fecha
técnica	período	elementos visuales
contexto histórico	enlace a Wikipedia	imagen

Entidades del modelo de datos:

- **Artwork:** entidad central (título, fecha, contexto histórico).
- **Author, Technique, Style:** metadatos referenciales (relación 1–N con Artwork).
- **ArtworkDescription:** descripciones textuales del contenido visual.
- **ArtworkNarration:** fragmentos narrativos y contextuales.
- **ArtworkAmbience:** elementos de ambientación con coordenadas (x, y).



Audio Descriptivo:

- Entrada: imagen de la obra + prompt estructurado.
- Procesamiento: Llama V4 Scout 17B genera descripción textual.
- Salida: Kokoro TTS convierte el texto en audio narrativo.

Narraciones de Contexto:

- Entrada: artículo de Wikipedia de la obra.
- Procesamiento: scraping + extracción de hechos clave + resumen narrativo.
- Salida: Kokoro TTS genera audio narrativo contextual.
- **Ventaja:** evita alucinaciones usando fuentes autoritativas en lugar de consultas directas al modelo.



```
DESCRIPTION_PROMPT = \
    """Describe los elementos retratados en la imagen.
    - Debe estar en un formato adecuado para narración.
    - Debe ser conciso y corto en duración.
    - NO seas redundante.
    - NO utilices títulos ni subtítulos.

    Elementos retratados: """
```

Listing 1: Prompt para Generación de Audio Descriptivo



```
SOURCE_SUMMARY_PROMPT = \
"""Eres un experto en redacción narrativa.
Lee el texto y escribe un resumen breve
(máx. dos párrafos) en estilo natural y fluido.
- Mantén un tono narrativo, claro y atractivo.
- Sé conciso: evita repeticiones o rodeos.
- Enfócate en los hechos principales y
  el contexto histórico de la obra.
Texto: {TEXT}
Tu respuesta: """
```

Listing 2: Prompt para Narraciones de Contexto

Sonidos Ambientales: Heurística



Pipeline de 3 pasos:

1. Segmentación
2. Extracción semántica
3. Síntesis de audio



Figure 3: Segmentación por Cuadrantes
Obra “El Aquelarre”



```
EXTRACTOR_PROMPT = \
    """Extract audio ambience keys from the image.
    - Output JSON: {"is_background": bool, "object": string}
    - Only objects with sound relevance, 3 max.
    - Alive → describe sound (goat bleating, barking).
    - Output just the required JSON.
    JSON RESULT: """
```

Listing 3: Prompt para Extracción de Elementos Sonoros



- Implementado en **NextJS**.
- Textos alternativos y etiquetas HTML descriptivas.
- Navegación mediante atajos de teclado.
- Placeholders en todos los inputs para lectores de pantalla.

Limitaciones



- Módulos generativos no se integraron directamente en la API Gateway.
- Se implementó un prototipo funcional en Jupyter para validar el flujo de procesamiento.
- Los datos fueron preprocesados y luego incorporados a la base de datos.

5 Resultados



- Autodocumentación Swagger/OpenAPI.
- Operaciones CRUD completas para todos los módulos
- Endpoints habilitan lectura/escritura de elementos preprocesados.
- Permite consulta general y gestión individual de obras, autores, períodos y técnicas.

Compatibilidad con APIs externas:

- Datos no estructurados (imágenes, audio) transmitidos en base64.
- Facilita integración con SDKs compatibles con API de OpenAI (Groq, Novita, TogetherAI).

SensorIA

Home Galería

Obra del día

The Tower of Babel

Leandro Bassano

The story of the Tower of Babel (Genesis 11: 1-9) is intended to explain the existence of different languages. After the Great Flood, all of humanity spoke the same language. Noah's great-grandson, Nimrod, decided to build a tower in Babel that would reach heaven. When God saw it, he was angry and made people speak different languages so they could no longer understand one another. The building stopped. Nimrod appears in the middle distance of Leandro Bassano's painting. Bricklayers work at either end of the large square tower on wooden scaffolding. A labourer carts bricks in a wheelbarrow while another mixes mortar with a long stick.



Buscar Obra

Q Search

Figure 4: Pantalla Principal de la Plataforma



SensorIA

HomeGalería

Titulo El aquelarre	Autor Francisco de Goya	Fecha 1798	Periodo Romanticismo	Técnica óleo sobre lienzo
-------------------------------	-----------------------------------	----------------------	--------------------------------	-------------------------------------

Descripción de la obra
En la imagen se puede observar una representación de un ritual o acto de adoración hacia un macho cabrío. La figura del macho cabrío viste una corona de hojas y se encuentra en el centro de la composición. Está rodeado de personas que

Narración de la obra
En el palacio de recreo de los duques de Osuna, situado en la finca de la Alameda de Osuna, a las afueras de Madrid, Francisco de Goya pintó seis pequeños cuadros entre 1797 y 1798. Uno de ellos, "El aquelarre", es una obra que representa

Figure 5: Vista de Obra con Metadatos y Audios

Caso de Estudio: “El Aquelarre” (Goya)



Obra representativa seleccionada para ilustrar el funcionamiento de los módulos generativos.

Se evaluaron:

- Calidad del texto en
 - Audio Descriptivo
 - Narraciones de Contexto.
- Fidelidad y realismo del audio ambiental.
- Naturalidad y claridad de la voz sintetizada (TTS).



Figure 6: Obra “El Aquelarre” de Francisco de Goya (1797–1798)

Resultados: Audio Descriptivo



Figure 7: “El Aquelarre”
Francisco de Goya (1797–1798)

En la imagen se puede observar una representación de un ritual o acto de adoración hacia un macho cabrío. La figura del macho cabrío viste una corona de hojas y se encuentra en el centro de la composición, rodeado de personas participando en una ceremonia.

Al fondo se ve una luna creciente en el cielo nocturno. Detrás del macho cabrío hay un grupo de personas vestidas con túnicas, algunas con la cara cubierta.

Listing 4: Descripción generada por Llama V4



En el palacio de recreo de los duques de Osuna, a las afueras de Madrid, Francisco de Goya pintó seis pequeños cuadros entre 1797 y 1798. "El aquelarre" representa un ritual de brujería presidido por un gran macho cabrío, forma del demonio, rodeado de brujas que entregan niños según la superstición de la época.

La serie forma parte de la estética del "sublime terrible", una corriente del prerromanticismo que buscaba generar desasosiego en el espectador. La brujería era un tema de actualidad entre los ilustrados españoles amigos de Goya.

Listing 5: Narración generada para obra
"El Aquellarre" de Francisco de Goya

Resultados: Sonidos Ambientales y TTS



Segmento	Sonidos Generados						
	<table><tr><td>Objeto</td><td>goat bleating</td></tr><tr><td>Fondo</td><td>tree branch creaking, people whispering</td></tr><tr><td>Audio</td><td>https://youtu.be/dqOECGiEiBI</td></tr></table>	Objeto	goat bleating	Fondo	tree branch creaking, people whispering	Audio	https://youtu.be/dqOECGiEiBI
Objeto	goat bleating						
Fondo	tree branch creaking, people whispering						
Audio	https://youtu.be/dqOECGiEiBI						
	<table><tr><td>Fondo</td><td>sand</td></tr><tr><td>Objeto</td><td>puppy sleeping</td></tr><tr><td>Audio</td><td>https://youtu.be/mT7UBvVd9m8</td></tr></table>	Fondo	sand	Objeto	puppy sleeping	Audio	https://youtu.be/mT7UBvVd9m8
Fondo	sand						
Objeto	puppy sleeping						
Audio	https://youtu.be/mT7UBvVd9m8						

Table 2: Elementos Detectados en "El Aquelarre"

6 Conclusión



Utilidad de LLMs multimodales para accesibilidad:

- Capaces de interpretar de manera integrada información visual y textual.
- Generan descripciones detalladas y coherentes a partir de imágenes artísticas complejas.
- Sustituyen, en gran medida, la percepción visual directa por mediación auditiva rica en contenido semántico.
- La adaptación del estilo narrativo y la cadencia facilita la conversión a audio vía TTS.

Ventajas de escalabilidad:

- Reducción de la dependencia de anotaciones manuales extensivas y metadatos preestructurados.
- Posibilidad de combinar análisis visual, generación de lenguaje y producción de audio en un mismo flujo.
- Construcción de soluciones integrales que responden a diversas necesidades de accesibilidad.

Trabajo Futuro y Potencial



Modelos generativos de audio:

- Alto potencial para contenido apreciativo e inmersivo.
- Necesidad de incorporar mecanismos human-in-the-loop para control de calidad.
- Garantizar coherencia, fidelidad y utilidad del contenido generado.

Mejoras identificadas:

- Integración real de módulos generativos en la API Gateway.
- Búsqueda con tolerancia a variaciones de acentuación (fuzzy matching).
- Etiquetado accesible de los componentes de ambientes sonoros.
- Migración a multipart-form-data para transmisión de archivos.
- Corrección de anglicismos y siglas en el pipeline TTS.
- Ampliación del catálogo de obras y enriquecimiento de metadatos.

Los modelos de lenguaje multimodales se posicionan como herramientas clave para democratizar el acceso al patrimonio cultural, ampliando la inclusión de públicos tradicionalmente excluidos de la experiencia artística visual.

7 Preguntas