

Diseño y Desarrollo de Plataforma de Apreciación Artística para Personas con Discapacidad Visual

**Memoria de Titulación
para optar al título de Ingeniero Civil Telemático**

22-06-2026

Alexey Nikolay Mitjaew Hupat

Contents



1	Introducción	5
1.a	Contexto y Problema	6
1.b	Oportunidad Tecnológica	7
1.c	Solución Propuesta	8
1.d	Objetivos	9
2	Marco Teórico	10
2.a	Modelos de Lenguaje Multimodales	11
2.b	Modelos Generativos de Audio	12
2.c	Modelos de Texto a Voz (TTS)	13
2.d	Estándares de Accesibilidad	14
2.e	Convergencia Tecnológica	15
3	Estado del Arte	16
3.a	Accesibilidad Cultural Tradicional	17
3.b	Comparación de Alternativas	18
3.c	Modelos Multimodales Evaluados	20
3.d	Modelos de Audio y Voz Evaluados	21

Contents (ii)



4	Desarrollo de la Plataforma	22
4.a	Requisitos Funcionales	23
4.b	Requisitos No Funcionales	24
4.c	Arquitectura General	25
4.d	Módulos del Sistema	26
4.e	Catálogo y Modelo de Datos	27
4.f	Módulos de Generación	28
4.g	Sonidos Ambientales: Heurística	29
4.h	Frontend y Limitaciones	30
5	Resultados	31
5.a	API Gateway	32
5.b	Frontend	33
5.c	Caso de Estudio: “El Aquelarre” (Goya)	34
5.d	Resultados: Audio Descriptivo	35
5.e	Resultados: Narraciones de Contexto	36
5.f	Resultados: Sonidos Ambientales y TTS	37

Contents (iii)



6	Conclusión	38
6.a	Síntesis de Resultados	39
6.b	Trabajo Futuro y Potencial	40
7	Bibliografía	41

1 Introducción

Contexto y Problema



- El acceso equitativo al arte es un componente esencial del desarrollo cultural y social.
- Las personas con discapacidad visual enfrentan barreras significativas para disfrutar obras visuales en condiciones comparables al resto del público.
- Las soluciones de accesibilidad convencionales (texto alternativo, audioguías manuales, maquetas táctiles) no logran traducir la experiencia estética completa:
 - Composición, color, textura y simbolismo.

Oportunidad Tecnológica



- La inteligencia artificial emerge como una oportunidad para reimaginar la transmisión de contenido artístico.
- Los modelos multimodales de lenguaje interpretan el contenido de una obra con profundidad semántica:
 - Identifican elementos, estilos, emociones y simbolismos.
- Los modelos generativos de audio transforman interpretaciones en experiencias sonoras inmersivas.
- Esta convergencia habilita una mediación artística automatizada y escalable.

Solución Propuesta



Este proyecto desarrolla una alternativa de accesibilidad para consumo de contenido artístico orientado a personas con discapacidad visual.

Pipeline integrada de producción de piezas de audio:

- Modelos de lenguaje multimodales para interpretación de obras.
- Sistemas de síntesis de voz (TTS) para narración.
- Modelos generativos de audio para paisajes sonoros.
- Cliente web accesible conforme a estándares WCAG.

Objetivos



Objetivo General:

Mejorar la experiencia estética y promover la accesibilidad universal a las obras de arte para personas con discapacidad visual, mediante una plataforma que utiliza IA para transformar imágenes de obras en paisajes sonoros y descripciones auditivas significativas.

Objetivos Particulares:

1. Proveer un catálogo curado de obras de dominio público.
2. Generar audios descriptivos del contenido visual.
3. Crear narraciones con contexto histórico/biográfico.
4. Producir ambientes sonoros inmersivos.
5. Diseñar una interfaz centrada en accesibilidad.

Aportes principales: Objetivos 1 y 4. Contribuciones significativas en módulos 2 y 3.

2 Marco Teórico

Modelos de Lenguaje Multimodales



- Sistemas de aprendizaje profundo que procesan, comprenden y generan texto en lenguaje natural.
- Extensión multimodal: integran contenido visual (imágenes) y auditivo.
- Capacidades clave para este proyecto:
 - Generar descripciones detalladas de escenas y composiciones artísticas.
 - Traducir elementos visuales en narrativas estructuradas.
 - Procesar entradas de voz en flujos conversacionales.

Modelos representativos del estado del arte:

- **Llama V4** (Meta): código abierto, codificación multimodal con MetaCLIP.
- **GPT-4o** (OpenAI): integración nativa texto-imagen-audio.
- **Gemini 1.5** (Google): procesamiento multimodal unificado.

Modelos Generativos de Audio



- Sistemas que crean sonidos y música a partir de prompts de texto.
- Basados en arquitecturas de aprendizaje profundo (difusión, transformers).
- Sintetizan desde sonidos ambientales hasta composiciones musicales.

Modelo de referencia:

- **AudioLDM:** genera audio ambiental mediante difusión latente condicionada por descripciones textuales.
- Utiliza embeddings CLAP para mejorar la alineación semántica texto-sonido.
- Pesos abiertos y preentrenados disponibles.

Modelos de Texto a Voz (TTS)



- Transforman texto escrito en habla sintética mediante NLP y síntesis de voz.
- Arquitecturas de referencia:
 - ▶ **Tacotron 2**: encoder-decoder con atención, genera espectrogramas mel autoregresivamente.
 - ▶ **VITS**: síntesis end-to-end con flujos normalizadores y aprendizaje adversarial.
 - ▶ **StyleTTS2**: modela variaciones de prosodia y timbre.

Implementación seleccionada:

- **Kokoro-82M**: voz de alta calidad con solo 82 millones de parámetros.
- Soporte nativo para español. Basado en StyleTTS2.

Estándares de Accesibilidad



- Marco normativo que guía el diseño de interfaces inclusivas.

WCAG (Pautas de Accesibilidad para el Contenido Web):

- Perceptibilidad, operabilidad, comprensibilidad y robustez.

Contexto chileno:

- Ley N.º 20.422: igualdad de oportunidades e inclusión social.
- Exigencias específicas para tecnologías asistivas.

Adopción en la plataforma:

- Compatibilidad con lectores de pantalla.
- Navegación por teclado.
- Descripciones alternativas y controles auditivos accesibles.

Convergencia Tecnológica



La plataforma integra estas tres tecnologías en un flujo coherente:

Imagen de obra → LLM Multimodal → Texto descriptivo / narrativo → TTS → Audio

Prompt textual → Modelo generativo de audio → Paisaje sonoro

Cliente web WCAG → API Gateway → Experiencia auditiva accesible

3 Estado del Arte

Accesibilidad Cultural Tradicional



Prácticas museográficas convencionales:

- Audioguías, maquetas táctiles, textos en braille, recorridos guiados adaptados.
- Guías oficiales de accesibilidad para museos.

Programas institucionales:

- Experiencias multimediales MAC (Museo de Arte Contemporáneo, U. de Chile): audioguías, cápsulas subtituladas, lengua de señas.
- Museo Emilio Caraffa (Argentina): sala accesible con QR, audiodescripciones y paisajes sonoros.

Proyectos independientes:

- **Audioguiarte:** audioguías personalizadas y recorridos accesibles.
- **MiméticasLab:** recreación táctil de obras con impresión 3D.

Comparación de Alternativas



Categoría	Ejemplos	Modalidades	Limitaciones
Accesibilidad museográfica	Audioguías, braille, signoguías	Audio, táctil, texto	Escalabilidad limitada, alta dependencia humana
Programas institucionales	MAC, Caraffa	Audio, video, señas	Alcance restringido a exposiciones específicas
Proyectos inclusivos	Audioguiarte, MiméticasLab	Audio narrativo, táctil	No universalizado ni automatizado
Investigación académica	MAIDR, arte a música	Texto, audio	Prototipos sin despliegue productivo
Plataformas digitales	Smartify, Google Arts & Culture	Imagen, texto, audio	Baja personalización en accesibilidad

Table 1: Estado del Arte en Accesibilidad Artística

Comparación de Alternativas (ii)



Brecha identificada: las soluciones actuales requieren procesos manuales o semiautomáticos, sin coordinación eficiente entre modalidades. Esto limita la escalabilidad.

Modelos Multimodales Evaluados



Criterios de selección: pesos abiertos, soporte multimodal nativo, inferencia cloud de bajo costo.

Modelos considerados:

- **Llama V4 (Meta):** seleccionado. Pesos abiertos, MetaCLIP, acceso vía Groq/Novita/TogetherAI.
- **GPT-4o (OpenAI):** integración nativa texto-imagen-audio. Sin pesos liberados.
- **Gemini 1.5 (Google):** procesamiento multimodal unificado. Sin pesos liberados.
- **DeepSeek-OCR:** código abierto, especializado en OCR y documentos visuales.

Llama V4 combina los tres factores requeridos simultáneamente.

Modelos de Audio y Voz Evaluados



Síntesis de voz (TTS):

- Tacotron 2, VITS, StyleTTS2: arquitecturas de referencia.
- **Kokoro-82M**: seleccionado. 82M parámetros, 3 voces en español, alta calidad.

Generación de audio ambiental:

- **AudioLDM**: seleccionado. Difusión latente + CLAP. Pesos abiertos.
- **I Hear Your True Colors**: VQVAE + transformers + CLIP. Sin pesos públicos.

Estado de la generación de audio ambiental: aún en fase experimental, sin soluciones comerciales consolidadas.

4 Desarrollo de la Plataforma

Requisitos Funcionales



- **Catálogo de obras:** construir, procesar y exponer un catálogo digital curado de obras de dominio público, con imágenes y metadatos.
- **Audio descriptivo:** generar descripciones textuales objetivas mediante modelos multimodales y convertirlas a audio con TTS.
- **Narración contextual:** extraer y sintetizar información histórica de fuentes autoritativas, producir narraciones auditivas.
- **Ambiente sonoro:** integrar modelos generativos de imagen a audio para producir paisajes sonoros.
- **Interfaz accesible:** cliente web conforme a WCAG, compatible con lectores de pantalla y navegación por teclado.

Requisitos No Funcionales



- **Accesibilidad:** interfaz intuitiva y compatible con herramientas asistivas.
- **Modularidad:** módulos de generación de contenido independientes y reemplazables.
- **Escalabilidad:** incorporar nuevas obras sin cambios estructurales.
- **Interoperabilidad:** servicios expuestos mediante API REST con endpoints documentados.

Modelo arquitectónico: cliente-servidor. Desacopla la interfaz de usuario del procesamiento computacionalmente intensivo (inferencia de modelos y procesamiento multimedia).

Arquitectura General



API Gateway como componente central:

- Centraliza el acceso a funcionalidades heterogéneas bajo una interfaz uniforme.
- Aísla los servicios internos, permitiendo evolución independiente.
- Concentra tareas de alto costo computacional en entorno controlado.

Tecnología: Django + Django REST Framework.

- ORM, arquitectura MVT, ecosistema de paquetes.
- Autenticación, manejo de rutas y middleware integrados.

Módulos del Sistema



La API Gateway orquesta 4 módulos funcionales:

1. **Catálogo:** gestiona los recursos del sistema y su persistencia.
2. **Generador de Audio Descriptivo:** transforma representaciones visuales en audios descriptivos. Utiliza Llama V4 para análisis de imágenes.
3. **Narrador de Contexto:** crea narraciones sobre el contexto histórico de cada obra a partir de fuentes autoritativas.
4. **Generador de Sonidos Ambientales:** sintetiza audio contextual con modelos autoalojados (AudioLDM) para representar las obras en formato interactivo.

Esta separación permite integrar servicios externos y soluciones autoalojadas en una arquitectura desacoplada y escalable.

Catálogo y Modelo de Datos



Dataset: 30 obras artísticas de dominio público en formato JSON.

Cada entrada contiene: autor, título, fecha, técnica, período, elementos visuales, contexto histórico, enlace a Wikipedia e imagen.

Entidades del modelo de datos:

- **Artwork:** entidad central (título, fecha, contexto histórico).
- **Author, Technique, Style:** metadatos referenciales (relación 1–N con Artwork).
- **ArtworkDescription:** descripciones textuales del contenido visual.
- **ArtworkNarration:** fragmentos narrativos y contextuales.
- **ArtworkAmbience:** elementos de ambientación con coordenadas (x, y).

Módulos de Generación



Audio Descriptivo:

- Entrada: imagen de la obra + prompt estructurado.
- Procesamiento: Llama V4 Scout 17B genera descripción textual.
- Salida: Kokoro TTS convierte el texto en audio narrativo.

Narraciones de Contexto:

- Entrada: artículo de Wikipedia de la obra.
- Procesamiento: scraping + extracción de hechos clave + resumen narrativo.
- Salida: Kokoro TTS genera audio narrativo contextual.
- **Ventaja:** evita alucinaciones usando fuentes autoritativas en lugar de consultas directas al modelo.

Sonidos Ambientales: Heurística



Pipeline de 3 pasos:

- 1. Segmentación:** la obra se divide en 9 cuadrantes (3×3).
- 2. Extracción semántica:** por cada cuadrante, Llama V4 detecta elementos con potencial sonoro (objetos, seres vivos). Salida en JSON con clasificación fondo/primer plano. Máximo 3 elementos por cuadrante.
- 3. Síntesis de audio:** AudioLDM genera sonido para cada elemento. Mezcla multicanal con volúmenes diferenciados:
 - Fondo: -20 dB
 - Primer plano: -5 dB

Frontend y Limitaciones



Frontend:

- Implementado en NextJS.
- Textos alternativos y etiquetas HTML descriptivas.
- Navegación mediante atajos de teclado.
- Placeholders en todos los inputs para lectores de pantalla.

Limitaciones del desarrollo:

- Por restricciones computacionales, los módulos generativos no se integraron directamente en la API Gateway.
- Se implementó un prototipo funcional en Jupyter para validar el flujo de procesamiento.
- Los datos fueron preprocesados y luego incorporados a la base de datos.

5 Resultados

API Gateway



- El sistema opera correctamente con autodocumentación Swagger/OpenAPI.
- Operaciones CRUD completas para todos los módulos.
- Debido a limitaciones computacionales, los endpoints solo habilitan lectura/escritura de elementos preprocesados.
- Permite consulta general y gestión individual de obras, autores, períodos y técnicas.

Compatibilidad con APIs externas:

- Datos no estructurados (imágenes, audio) transmitidos en base64.
- Facilita integración con SDKs compatibles con API de OpenAI (Groq, Novita, TogetherAI).
- Mejora futura propuesta: migrar a multipart-form-data para optimizar rendimiento.

Frontend



- Navegación evaluada mediante herramientas de accesibilidad para discapacidad visual.
- **Búsquedas:** por obra, autor, período y técnica. Limitación: coincidencia exacta de strings (incluyendo acentuación).
- **Placeholders** en todos los inputs facilitan la integración con utilidades de accesibilidad.
- **Vista de obra:** metadatos generales + contenido de módulos de narración y descripción con audios TTS.
- **Ambientes sonoros:** acceso mediante click/selección de 9 cuadrantes.
 - Carencia de etiquetado adecuado que indique la funcionalidad.
 - Mejora pendiente: etiquetado explícito de contenidos e interacción.

Caso de Estudio: “El Aquelarre” (Goya)



Obra representativa seleccionada para ilustrar el funcionamiento de los módulos generativos.

Se evaluaron:

- Calidad del texto en Audio Descriptivo y Narraciones de Contexto.
- Fidelidad y realismo del audio ambiental.
- Naturalidad y claridad de la voz sintetizada (TTS).

Resultados: Audio Descriptivo



Calidad del texto generado:

- Notable correspondencia entre las imágenes de entrada y las descripciones.
- Estructura sintáctica y cadencia adecuadas para procesamiento TTS.

Hallazgo clave: una estrategia de prompting directo resulta suficiente para que un modelo multimodal genere descripciones precisas, sin requerir fuentes externas de referencia.

Resultado con “El Aquelarre”: descripción objetiva del ritual, el macho cabrío en el centro, las figuras circundantes, la luna creciente y la atmósfera nocturna.

Resultados: Narraciones de Contexto



- Las narraciones se generan a partir de artículos de Wikipedia para evitar alucinaciones.
- Comparación cruzada con la fuente original demuestra adecuada correspondencia.
- El pipeline transforma contenido enciclopédico en narración fluida y de carácter natural.

Limitaciones identificadas:

- Casos borde con anglicismos y siglas.
- El TTS interpreta términos extranjeros con reglas fonéticas del español.
- Requiere preprocesamiento adicional o diccionario de excepciones.

Resultados: Sonidos Ambientales y TTS



Sonidos Ambientales:

- Detección de elementos generalmente coherente con la temática de la obra.
- Alucinaciones ocasionales en la identificación de componentes específicos.
- Calidad de audio: resultados verosímiles en la mayoría de los cuadrantes.
- Ruido y artefactos variables; outliers donde los ambientes degeneran en ruido.
- **Conclusión:** limitaciones en la generalización ante elementos visuales ambiguos.

Text-to-Speech (Kokoro 82M):

- Naturalidad adecuada para español, entonación fluida y pronunciación clara.
- Tono neutral apropiado para accesibilidad cultural.
- Problemas con anglicismos y siglas (interpretados con fonética española).

Audios de referencia en YouTube (descripción y narración de “El Aquelarre”).

6 Conclusión

Síntesis de Resultados



Utilidad de LLMs multimodales para accesibilidad:

- Capaces de interpretar de manera integrada información visual y textual.
- Generan descripciones detalladas y coherentes a partir de imágenes artísticas complejas.
- Sustituyen, en gran medida, la percepción visual directa por mediación auditiva rica en contenido semántico.
- La adaptación del estilo narrativo y la cadencia facilita la conversión a audio vía TTS.

Ventajas de escalabilidad:

- Reducción de la dependencia de anotaciones manuales extensivas y metadatos preestructurados.
- Posibilidad de combinar análisis visual, generación de lenguaje y producción de audio en un mismo flujo.
- Construcción de soluciones integrales que responden a diversas necesidades de accesibilidad.

Trabajo Futuro y Potencial



Modelos generativos de audio:

- Alto potencial para contenido apreciativo e inmersivo.
- Necesidad de incorporar mecanismos human-in-the-loop para control de calidad.
- Garantizar coherencia, fidelidad y utilidad del contenido generado.

Mejoras identificadas:

- Integración real de módulos generativos en la API Gateway.
- Búsqueda con tolerancia a variaciones de acentuación (fuzzy matching).
- Etiquetado accesible de los componentes de ambientes sonoros.
- Migración a multipart-form-data para transmisión de archivos.
- Corrección de anglicismos y siglas en el pipeline TTS.
- Ampliación del catálogo de obras y enriquecimiento de metadatos.

Los modelos de lenguaje multimodales se posicionan como herramientas clave para democratizar el acceso al patrimonio cultural, ampliando la inclusión de públicos tradicionalmente excluidos de la experiencia artística visual.

7 Bibliografía

Trabajo Futuro y Potencial (iii)



Referencias principales:

- **UNESCO.** Artículo 30 — Participación en la vida cultural, la recreación, el esparcimiento y el deporte.
- **W3C.** Web Content Accessibility Guidelines (WCAG). Pautas de accesibilidad para contenido web.
- **Ley N.º 20.422.** Igualdad de oportunidades e inclusión social de personas con discapacidad. Chile.
- **Meta.** Llama V4. Modelo de lenguaje multimodal con codificación MetaCLIP y pesos abiertos.
- **OpenAI.** GPT-4o. Modelo multimodal con integración nativa de texto, imagen y audio.
- **Google.** Gemini 1.5. Modelo de procesamiento multimodal unificado.
- **Liu et al.** AudioLDM. Generación de audio mediante difusión latente condicionada por texto.
- **Wu et al.** CLAP. Contrastive Language-Audio Pretraining.
- **Shen et al.** Tacotron 2. Síntesis de voz con arquitectura encoder-decoder y vocoder neural.
- **Kim et al.** VITS. Síntesis de voz end-to-end con flujos normalizadores.

Trabajo Futuro y Potencial (iv)



- **Kokoro TTS.** Modelo TTS de 82M parámetros con soporte para español.
- **Smartify, Google Arts & Culture.** Plataformas digitales de difusión cultural.
- **Museo de Arte Contemporáneo (MAC).** Experiencias multimediales para la accesibilidad.
- **MAIDR.** Representación multimodal de visualizaciones para accesibilidad.